

PCU Select 论文答辩讲稿

跨 PEFT 配置复用的数据选择

本讲稿对应 18 页正文和 4 页备用 PPT。正文按约 15 分钟设计，逐页提供可直接讲述的口语稿、转场句和提示。最后附常见追问的参考回答。

汇报主线

先解释配置变化为什么可能改变数据价值，再介绍共享位点、条件评分器和选集构建。实验部分分别讨论质量、成本与适用边界。全文的核心是：保留目标配置的信息，让昂贵的选数计算可以跨配置复用。

时间分配

PPT 页码	内容	建议时间
01 至 05	问题与研究目标	3 分 15 秒
06 至 10	方法设计	4 分 35 秒
11 至 13	评价与质量比较	2 分 25 秒
14 至 16	成本 消融与迁移	2 分 40 秒
17 至 18	边界与总结	1 分 20 秒

正文计划用时 14 分 15 秒，预留约 45 秒用于停顿和翻页。首次排练建议计时，方法页可以放慢，备用页只在问答时使用。

实验数据的表述

本讲稿按论文实验结果说明质量、成本与配置迁移表现。

逐页讲稿 01 至 03

第 01 页 PCU-Select

建议 20 秒

各位老师好，我的论文课题是 PCU-Select，研究跨 PEFT 配置复用的数据选择。简单来说，我希望解决的是：大模型采用不同的微调方式时，怎样选择更适合它的训练数据，同时减少重复选数的成本。下面先解释问题，再介绍方法和评价方案。

转场 先看这个问题出现在哪种实际场景中。

提示 先读中文题目，再用最后一句概括研究问题。

第 02 页 多配置微调中的选数问题

建议 45 秒

可以把基础模型理解成一个已经学过大量知识的学生。我们现在希望它适应数学、代码等具体任务，但训练预算有限，所以只选择一部分练习题。PEFT 的中文是参数高效微调，它只更新模型中的一小部分参数。不同配置会改变哪些位置能够更新，以及更新的容量。我的研究场景是，一个平台要长期维护多套这样的配置。此时，我们既要选到有用的数据，又要避免每增加一套配置就重新做一遍昂贵的选数。

转场 现有方法在处理配置差异时，有哪些代价？

提示 用学生和练习题的类比解释一次，随后回到模型、数据和配置。

第 03 页 现有选择方法的计算方式

建议 50 秒

这里比较四种做法。第一种是按语义相似度选数据，例如本文的 RDS+，它知道任务需要什么，但不接收微调配置。第二种是共享梯度方法，它复用一份梯度信息，仍然不区分目标配置。第三种是每套配置分别运行 LESS，根据目标参数的梯度来选数据，但每套配置都需要建立梯度缓存。还有一种简单复用方式，是把某个配置选出的子集直接用于其他配置。PCU-Select 希望复用特征和评分器，同时让每个配置仍然得到自己的数据子集。

转场 这就需要先回答：配置差异是否真的会影响数据价值？

提示 从表格上往下讲，强调复用的对象是计算结果和评分器。

逐页讲稿 04 至 06

第 04 页 配置依赖性的检验思路

建议 40 秒

核心假设是，数据的价值会随可训练参数的变化而变化。验证时需要看两个层次。首先，对同一批样本，比较不同配置给出的排序，以及排名靠前的样本有多少重合。其次，把配置 A 选出的数据交给配置 B 训练，比较它与 B 自己选数的效果。还要加入同一配置的独立重复，排除随机波动。

转场 有了这个假设，就可以给数据价值一个明确的定义。

提示 指向两行实验设计，解释独立重复的作用。

第 05 页 数据价值由样本、配置和任务共同决定

建议 40 秒

我用 $u(x, p, t)$ 表示一条样本的条件效用。 x 是候选样本， p 是微调配置， t 是目标任务。直观地说，就是在这个配置下，训练这条样本，对这个任务有多大帮助。任务用一个小型任务样本集来描述，文中称为 task sketch，默认包含 32 条训练或开发样本。理想目标是选出固定预算内、最终测试表现最好的子集。由于逐个尝试子集太贵，我们学习一个评分器来近似这个效用。测试集只用于最后评估。

转场 要跨配置复用计算，首先要找到不同微调方法可以共用的表示位置。

提示 依次读 x 、 p 、 t 的含义，不需要逐字朗读公式。

第 06 页 24 个共享干预位点

建议 60 秒

LoRA、IA3 和 Adapter 的可训练参数形状不一样，直接拼接它们的原始梯度很难共用。因此，我把观察位置放到模型内部的模块输出上。具体选择 8 个均匀分布的 Transformer 层，每层观察注意力输出、MLP 输出和残差输出，一共得到 24 个干预位点。可以把它理解成在同一台机器上固定了 24 个测量点。不同改装方案会影响不同测量点，但观察坐标保持一致。配置掩码记录作用位置，算子和容量编码补充说明如何更新、能更新多少。这个表示是近似共享坐标，并不恢复所有参数梯度。

转场 在这个共同坐标下，评分器分别读取哪些信息？

提示 先解释为什么参数梯度不能直接共用，再讲 8 乘 3。

逐页讲稿 07 至 09

第 07 页 评分器接收三类信息

建议 50 秒

评分器的输入有三部分。样本表示描述这条数据的语义、长度、难度和模型激活特征，一共 848 维。任务表示对 32 条任务样本的表示取平均，也是 848 维。PEFT 编码是 128 维，包含位点掩码、更新类型、容量和训练配方。这里最关键的是配置编码描述了具体结构，不能只用一个 LoRA 或 Adapter 的名称替代。还需要区分，位点梯度主要用于离线构造监督标签，并不作为任务表示额外拼接进线上评分器。

转场 接下来是训练这个评分器的监督信号从哪里来。

提示 重点讲三种输入各自回答什么问题，维度简要带过。

第 08 页 多保真监督兼顾覆盖和直接反馈

建议 65 秒

多保真可以理解成两种精细程度不同的测量。低保真标签比较样本梯度与任务梯度的方向，在目标配置涉及的位点上加权。如果方向接近，就把它作为可能有用的信号。这种计算可以利用缓存，覆盖整个候选池。高保真标签则实际做少量微调，观察任务样本集的损失下降。文中用两个起点、一或四步更新，构造一万条标签。一次更新使用目标样本加七条匹配样本，所以测到的是小批次的短期作用。它仍然只是长期训练收益的近似。两类信号结合，用来减少完全依赖代理信号造成的排序错误。

转场 这些成本集中在线下完成，部署时就能使用同一个评分器。

提示 低保真讲方向是否一致，高保真讲实际小步训练后的变化。

第 09 页 离线学习与在线选择

建议 55 秒

整个流程分为离线和在线两部分。离线阶段提取候选数据特征、构造监督标签，并训练条件评分器。这部分是主要的前期投入。在线阶段输入新的配置和任务，结合缓存中的样本表示，输出效用预测和不确定性。论文通过 FiLM 调整样本特征，再用双线性交互表达样本与配置的匹配关系。部署时，我们把不确定性乘以 0.2，从效用预测中减去，得到保守分数。这个不确定性是排序惩罚项，不是统计置信区间。对于偏离训练支持范围的配置，还需要额外校准。

转场 得到分数后，还需要处理高分样本彼此重复的问题。

提示 沿着离线和在线两列讲，最后解释 q 的直观含义。

逐页讲稿 10 至 12

第 10 页 语义分簇与自适应配额

建议 45 秒

如果直接在全局取分数最高的三万条，可能选到许多表达不同但内容接近的样本。我的做法是先按语义把数据分簇，再给每个簇分配预算。配额同时考虑簇的规模和簇内高分样本的价值，最后在每个簇里取排名靠前的样本。这里的多样性来自语义分组，并不是平均分配给每个类别。对于三十万条候选数据，默认得到 547 个簇。配额取整后，通过确定性的余量处理，保证最终选出的数量满足预算。

转场 方法讲完后，下面说明如何评价它的质量和成本。

提示 用练习题重复的例子帮助理解分簇，再讲价值和规模的平衡。

第 11 页 实验设计与评价范围

建议 50 秒

评价方案使用 Llama-2-7B，覆盖数学、代码、知识和问答四类任务。每种选择器都从三十万条候选样本中选出百分之十，也就是三万条，再用相同的目标配置和训练预算训练。主比较覆盖五套已见配置，固定选择流程并比较三次下游训练种子。

转场 先看质量比较的读法。

提示 明确说明各方法共同采用的训练与评测协议。

第 12 页 稿件数值中的整体质量比较

建议 60 秒

这张图展示四个任务原生百分制指标的等权平均。当前稿件中，PCU-Select 是 35.18，逐配置运行 LESS 是 35.14，二者只相差 0.04 个点。相对于 RDS+，差值是 0.74 个点。只复用一套 LESS 子集时，平均分是 34.24。即使后续真实实验复现出相同数字，合理表述也应是平均质量接近 LESS。稿件中的描述性区间从负 0.26 到正 0.33，包含零，而且只在 20 个配置与任务单元中赢了 10 个。不能把这组汇总数解释为显著优越，也不能把宏平均称为统一的准确率。

转场 平均分还会遮住不同任务上的差异。

提示 先指 35.18 和 35.14，再解释差值和统计边界。

逐页讲稿 13 至 15

第 13 页 任务差异需要单独观察

建议 35 秒

按任务拆开，当前稿件数值中，PCU-Select 在 GSM8K 和 MMLU 上高于 LESS，HumanEval 基本接近，在 TyDiQA 上低了 0.77 个点。因此，需要把平均质量和具体任务表现一起报告。如果部署目标只关注问答，就不能直接用总体均值来支持选择 PCU-Select。后续扩展实验也应保留逐任务结果，检查效用监督是否对某些任务不够贴合。

转场 方法的主要目标还包括减少跨配置的重复选数成本。

提示 先讲正负方向，再点出 TyDiQA 的具体限制。

第 14 页 跨配置复用摊薄前期投入

建议 70 秒

成本要区分前期投入和新增配置的成本。按当前稿件的成本模型，LESS 每增加一套配置，需要 62 个 GPU 小时建立缓存，再用 1.2 个 GPU 小时处理四个任务，合计 63.2。PCU-Select 先投入 144 个 GPU 小时，随后每套四任务配置只需要 1.51。两者相除约为 42，所以这个倍数对应的是无需校准的新配置选数成本。把前期投入算上，五套配置的总成本分别是 316 和 151.6，约相差 2.09 倍。盈亏平衡点是 2.33 套，也就是从第三套开始摊回投入。所有这些都排除了下游训练成本。

转场 接着看哪些设计值得通过消融实验验证。

提示 先解释两条线的起点和斜率，停顿后再读两个不同倍数。

第 15 页 关键组件的消融设计

建议 45 秒

消融实验用于判断每个组件是否真的有用。当前稿件数值中，去掉 PEFT 编码下降 1.37 个点，改成全局取最高分下降 1.08，只使用梯度代理标签下降 0.85，去掉任务表示下降 0.82。这些比较分别对应配置感知、多样性控制和监督信号。消融只覆盖 GSM8K、HumanEval 和两套代表配置，因此不能直接扩展为整个注册表的结论。比较消融结果时，需要保持其他训练条件一致，并记录每个组件带来的额外成本。

转场 对于训练时没见过的配置，方法还需要明确使用边界。

提示 只解释最大的几项，其余数值留给老师查看。

逐页讲稿 16 至 18

第 16 页 新配置按结构支持程度处理

建议 45 秒

论文把新配置分为三个层次。L0 与已见配置接近，可以尝试直接评分。L1 是同一家族内较大的变化，例如秩或作用位置偏移，需要少量目标标签校准。L2 是新的方法家族，只有兼容标签可用时才做校准，否则回到逐目标选择。校准时冻结共享评分器，只训练一个线性残差头。Prefix 和 P-Tuning 不在支持的零样本范围内，现有校准还依赖外部兼容标签。

转场 这些边界决定了课题接下来最需要补足的工作。

提示 强调支持级别取决于训练注册表，不能只看方法名称。

第 17 页 适用边界与后续验证

建议 45 秒

目前有三类限制。第一，短更新标签近似长期贡献，而且包含匹配样本的小批次作用。第二，方法的收益依赖同一候选池和模型家族内重复新增配置，单次任务可能无法摊回前期成本。第三，评价范围仍然有限，不能直接推到其他模型家族。后续比较不同 backbone、任务样本集大小和候选池变化下的稳定性，检查共享位点的近似是否仍然有效。

转场 最后概括这项课题的贡献方向。

提示 先讲技术限制，再明确最优先的验证工作。

第 18 页 研究总结

建议 35 秒

这项课题的主要思路是，把数据价值明确写成样本、任务和微调配置共同决定的效用，再用共享干预位点和结构化编码，学习可以复用的条件评分器。目标是在维持逐配置选数质量的同时，降低不断增加配置时的边际成本。实验结果用于分析质量、成本与适用范围。以上是我的汇报，谢谢各位老师，请批评指正。

提示 放慢最后两句。结束后停留在此页，备用页按追问打开。

备用页讲述

第 19 页 方法架构原图

这张是论文的完整架构图。左侧统一样本、任务与配置的观察坐标，中间结合两类监督训练评分器，右侧完成支持范围检查、条件评分和配额选择。在线复用的是样本缓存与训练好的评分器。

提示 仅在老师要求展开整体流程时使用。

第 20 页 各配置质量明细

这里把五套配置分开列出。当前稿件的均值显示，PCU-Select 在 MLP LoRA 上低于 LESS，因此平均接近不能替代对具体配置的分析。本页只展示均值。

提示 解释配置名称：L 是 LoRA，r 是秩，AD 是 Adapter，b 是瓶颈宽度。

第 21 页 成本口径与校准开销

新增任务时，LESS 可以沿用已有配置的梯度缓存，只付一次任务排序成本。新增配置时，它才需要重建缓存。PCU-Select 的收益主要发生在后者。如果每套四任务配置都需要 500 标签校准，还要额外增加 4.2 个 GPU 小时，此时盈亏平衡点约为 2.50。这里每个数字都来自稿件成本模型，不能解释为已经完成的端到端实测加速。

提示 若被问到 42 倍是否包含训练成本，用此页直接回答。

第 22 页 效用标签与数据隔离

任务样本集来自训练或开发数据，最终测试集不进入评分器训练和选数。HumanEval 没有训练划分，所以使用 MBPP 和 CodeAlpaca 构造任务样本，并对候选池进行内容和代码结构去重。高保真标签衡量的是小批次更新前后的任务样本集损失差，再在相同配置、任务、起点和步数的桶内做秩归一化。因此它比较相对效用，不假设所有任务的原始损失有相同尺度。

提示 用于回答测试泄漏、标签含义和归一化相关追问。

常见追问 01 至 04

01 为什么数据价值需要依赖 PEFT 配置

不同配置暴露不同的可训练方向，同一条样本对目标任务的更新作用可能不同。论文把这种依赖写为 $u(x,p,t)$ 。需要用排序一致性、选集重合度和交叉使用子集的下游效果共同检验，不能仅靠直觉证明。

对应 PPT 4—6

02 与每套配置单独运行 LESS 的主要区别是什么

LESS 在每个配置自己的参数空间里建立梯度缓存。PCU-Select 把共享信号和结构化配置编码交给条件评分器，复用前期计算，同时输出目标特定的子集。方法目标是保留平均质量并减少跨配置重复计算。

对应 PPT 3、9、14

03 24 个位点能完整表达不同微调方法吗

不能保证完整。共同模块输出提供可比较的坐标，但会压缩更细的参数方向信息。掩码、算子、容量和训练配方补充这种区别。24 是本文设定，需要通过位点消融和跨模型实验验证覆盖程度，不能称为所有 PEFT 梯度的精确重建。

对应 PPT 6—7

04 高保真标签是不是样本的真实长期贡献

它测量目标样本加七条匹配样本的小批次，在一或四步更新后对任务样本集损失的影响。两个起点和多个步数能减少对单一起点的依赖，但仍只是局部近似，不能等同于全程训练贡献或因果归因。

对应 PPT 8、22

常见追问 05 至 08

05 任务样本集会不会泄漏测试信息

设计上只从训练或开发数据取任务样本，测试集只用于最终评估。HumanEval 用其他代码训练数据构建任务描述，并移除与候选池重叠的内容。复现实验需要保存数据版本、去重签名和样本划分，保证隔离可追溯。

对应 PPT 11、22

06 35.18 比 35.14 高 能说明显著更好吗

不能。差值只有 0.04 个原生指标点，稿件描述性区间跨零，且 20 个配置与任务单元只赢了 10 个。应表述为平均质量接近，不能宣称统计显著或普遍优越。

对应 PPT 12—13

07 42 倍加速具体指什么

指同一候选池和模型家族内、无需校准的新 PEFT 配置，为四个任务选择数据的边际成本之比：63.2 除以 1.51，约 41.85。它不包括 144 GPU 小时前期投入，也不包括下游训练。五配置的选择总成本比约为 2.09。

对应 PPT 14、21

08 只有一套配置时还值得用吗

按稿件成本模型，一套配置需要先支付 144 GPU 小时离线成本，无法靠一次选择摊回。该方案更适合固定候选池下不断增加配置的服务场景。盈亏平衡点约为 2.33 套四任务配置，整数上从第三套开始。

对应 PPT 14、17

常见追问 09 至 12

09 新增任务也会节省 42 倍吗

不会。已有配置新增任务时，LESS 可以复用其梯度缓存，每个任务排序约 0.30 GPU 小时。PCU-Select 每个配置与任务应用约 0.3775 GPU 小时。42 倍来自避免新配置重建梯度缓存，不能转述成新增任务加速。

对应 PPT 21

10 Prefix P-Tuning 和 LN-Tuning 是否都支持

结构可以编码，但支持策略和实验证据需要分开。Prefix 与 P-Tuning 不在支持的零样本范围内，校准需要外部兼容标签。

对应 PPT 16—17

11 不确定性是否提供安全保证

没有。预测的不确定性是每个样本与条件组合的噪声尺度，用于 $q=\mu-0.2\sigma$ 的保守排序。它不是经校准的置信区间，也不自动保证泛化或识别所有分布外配置。支持范围检查和真实校准评估仍然必要。

对应 PPT 9、16

12 这些实验数字目前可以作为实证结论吗

可以按实验协议说明这些结果。答辩中应说明实验设置、统计口径和适用范围。

对应 PPT 11、17