



华南理工大学
South China University of Technology

研究生学位（毕业）论文中期考核表

移动边缘网络中的模型聚合方法研究

研 究 生：_____陈瑾如_____

指导教师：_____杨磊_____

学 号：_____202121047085_____

院（系）：_____软件学院_____

专 业：_____软件工程_____

☐ 博士研究生

☒ 硕士研究生

华南理工大学研究生院

二〇二三年四月

一、中期考核工作基本情况

开题报告题目	基于协作学习的逻辑通信拓扑优化方法研究
文献综述题目	基于移动边缘网络中的协作学习研究综述
课题研究的创新点： 1 背景及动机 在移动计算和物联网（IoT）的推动下，网络中广泛分布的终端设备在边缘产生了大量数据。为了减少延迟和数据传输，人们提出了边缘学习，在更靠近数据源的边缘设备上处理数据。它在网络边缘部署分布式机器学习模型，并利用边缘设备集群进行模型训练。为了保护用户隐私，它结合了联合学习，在训练过程中传输模型参数或更新，而无需收集用户的原始数据。边缘学习已在实际物联网环境中得到广泛应用，如车辆网络、无人机网络和灾难救援等。 边缘网络具有动态特性。这是因为它们由大量不可靠的边缘设备组成，由于硬件故障、节点移动和资源共享等原因，网络拓扑和性能会发生动态变化。首先，边缘设备通常是移动的，会随着用户位置的变化而变化。例如，车辆和智能手机经常连接到不同的基站和无线接入点。其次，由于硬件和软件问题，边缘设备可能会出现设备崩溃和运行缓慢的情况。设备故障会导致网络中节点的频繁加入和离开。由于节点的移动性和故障，边缘网络的拓扑结构会不断变化。此外，除了固有硬件限制导致的性能差异外，边缘节点还可能因使用共享计算、存储和网络资源而表现出不可预测的性能差异。例如，在利用共享网络或集群的实际系统中，节点性能可能会受到其他用户和应用的影响，从而导致节点计算能力的波动。 模型聚合是边缘学习的重要步骤。它将多个边缘节点的局部模型结合起来，生成具有更好泛化能力的全局模型。边缘节点根据预定义的结构执行模型聚合。选择合适的模型聚合结构可以提高模型训练的效率，充分利用边缘环境中存在的多样化数据。现有的构建模型聚合结构的方法可分为静态和动态两种，取决于聚合结构在训练过程中是否主动发生变化。 静态方法往往不能适应动态边缘环境，导致模型训练性能下降。静态方法，如 E-tree 和 FedCH，依赖于在一段时间内收集的全局信息，在具有相似性能和互补数据分布的节点之间聚合模型。他们假设环境在训练过程中不会发生重大变化，这在边缘环境中通常不是这样。在动态变化的边缘环境中，节点经常浪费资源等待预先确定的通信伙伴。 大多数动态方法使用集中式服务器来优化聚合结构，这在大规模边缘计算中带来了很高的通信和管理开销。CASP、GossipFL 等方法，针对当前环境优化聚合结构。然而，这些方法通常依赖于集中式服务器来收集全局信息。在实际环境中，边缘节点在地理上是分布的，通过集中式服务器获取全局信息会带来巨大的成本和延迟。另一方面，由于缺乏对 non-IID 数据等现实问题的考虑，现有的去中心化动态方法的收敛性能较差。 为了解决在缺乏全局信息的情况下构建聚合结构的挑战，我们提出了一种去中心动态方法，称为自治模型聚合结构(AMAS)。它使节点能够在每一轮训练结束后，通过与其他节点的通信，确定适合自己的聚合结构。该方法减少了动态环境中节点的等待时间和通信时间。此外，为了保证边缘设备上数据的最优利用，AMAS 在每一轮结构构建中都会根据模型相似度和历史信息选择	

合适的聚合节点。

2 创新点

①我们探讨了现实环境中现有聚合结构构建方法存在的问题，并设计了一种方法，允许节点自主构建聚合结构，而无需依赖全局信息。该方法更适用于动态变化、全局信息难以获取的真实边缘环境。

②在构建聚合结构时，我们会考虑节点的准备情况、通信差异和模型相似性。这确保了节点的计算和通信能力得到充分利用，同时减少了统计异质性对训练的影响。

开题以来研究工作总结：

1 问题定义

边缘学习通过迭代聚合来自多个边缘设备的本地模型来获得泛化性能更好的全局模型。它将模型聚合从云迁移到边缘节点。每个节点都有一个本地版本的模型参数，并根据聚合结构执行模型聚合。

我们考虑一个由 N 个边缘设备组成的系统，其中每个边缘设备 V_i 都有一个本地数据集 D_i 。不同设备的数据集的大小和分布可能各不相同，我们将全局数据集定义为 $D \triangleq \sum_{i=1}^N D_i$ 对于每个边缘设备 i ，它们使用其本地数据集训练一个本地模型 ω_i ，损失函数为 $F_i(\omega_i) \triangleq \frac{1}{|D_i|} \sum_{j \in D_i} f_j(\omega_i)$ 。其中， $f_j(\omega_i)$ 是第 j 个数据样本的损失函数 $f(x_j, y_j, \omega_i)$ 的简写， x_j 代表输入样本， y_j 是相应的标签， $|D_i|$ 表示边缘设备 i 的本地数据集的大小。

我们假设边缘节点通过无线通信技术连接起来，形成一个分布式的去中心网状拓扑网络。每个节点都是平等的，并与其他节点协作实现模型训练，使用广播或多跳转发进行模型传输。这种网络在救灾、野外探险、军事作战等各个领域都有广泛的应用。节点 i 和 j 之间的网络带宽表示为 B_{ij} ，它会根据实际的网络拓扑结构而变化。对于每个边缘设备 $i \in N$ ，让 $nhr(i) \subset \{1, 2, \dots, N\} \setminus \{i\}$ 表示节点 i 的邻居集。边缘设备交换参数，协作学习模型。其训练目标是使每个节点在尽可能短的时间内收敛到一个通用的全局模型，并使全局损失最小。因此，目标函数定义为

$$\begin{aligned} \min_{\omega, \{\omega_i\}_{i=1}^N} \quad & \sum_{i=1}^N F_i(\omega_i) \\ \text{s.t.} \quad & \omega_i = \omega, \forall i. \end{aligned}$$

2 方法设计

2.1 聚合分组协议

考虑到节点的异构性能，我们采用异步方法来实现模型聚合，以减少节点的等待时间和有效利用边缘设备的计算通信资源。为了应对节点性能和网络拓扑的动态变化，我们有必要动态地构建聚合结构。在大规模环境中每个节点都缺乏对系统的全局了解，构建集中式聚合结构将产生更高的成本和延迟，因此我们需要构建一种去中心聚合结构。基于上述考虑，我们得出结论：我们需要提出一种异步的动态的构建去中心聚合结构的方法。为实现这一目标，我们提出了一种简单

的分布式协议来在训练过程中构建聚合分组。在系统中，每个节点最初只拥有本地信息。为了构建合适的聚合分组，节点需要与其他节点进行协商。以下是我们提出的分组过程。

步骤 1：一开始，所有节点都处于“训练者”状态，进行本地训练。

步骤 2：一定迭代次数之后，节点进入聚合阶段，状态变为“自由者”。“自由者”在随机等待时间内等待接收邀请信号。

步骤 3：等待时间结束后，如果某个节点还没有加入合适的分组，它的状态就会变为“领导者”。领导者会主动向其他节点发出邀请。为了控制分组内模型传输的延迟，邀请信号会发送给通信距离小于阈值的一组节点。邀请信号包括领导者信息和过期时间。过期时间一到，邀请就会被丢弃。如果过期时间未到，但发出邀请的领导者已经组建了分组，则该邀请也被视为无效，领导者将拒绝来自过期邀请的追随者。

步骤 4：节点接收邀请信号并将其保存在邀请队列中。必要时，节点会根据自己的当前状态决定是否成为“追随者”。当队列中有多个有效邀请时，节点会向最近收到的邀请中通信距离最短的节点发送跟随信号。

步骤 5：当领导者收集到所需数量的节点后，就会停止接受新成员，并拒绝之后的追随者。然后，领导者再根据成员选择标准选择合适的节点组成分组，同时拒绝不合适的节点。不合适的节点会回到自由者状态，寻找新的领导者，或等到等待时间结束后自己成为领导者。目前，成员选择考虑了节点的模型相似性和历史信息。一旦被接受，跟随者就会将自己的状态改为“成员”。领导者会聚合成员的模型参数，并将聚合后的模型和当前分组发送给所有成员。

步骤 6：每一轮聚合之后，领导者和成员都会恢复到“训练者”状态，并继续进行本地训练。




图 1. 分组聚合协议

在小组构建过程中，我们主要考虑节点的就绪时间及其通信能力。由于动态异构的存在，节点的实际训练时间不能完全根据理论来计算。因此，我们参考 P-reduce，将节点的就绪时间作为分组的依据。只有准备就绪的节点才能开始构建聚合结构，避免了掉队者和故障节点对其他节点训练的影响。组长的邀请信号只发送给通信距离小于通信阈值的节点集，同时节点会在收到的多个邀请中选择通信条件最好的节点跟随，以控制节点的通信时间，防止组内通信时间过长。

3.2 节点选择

(1) 模型相似性。在节点间存在 non-IID 数据的情况下，组内数据的分布会影响聚合模型的性能。在静态的方法中，组内数据分布更接近全局数据分布可以提高模型训练的收敛速度。我们认为，在动态构建聚合结构的时候，尽可能使数据分布与全局数据分布一致对提高模型性能也是有利的。因此，我们可以在节点自主构建聚合结构时，额外多接收部分节点，并过滤掉一些不合适的节点。

为了验证这一点，我们使用 CIFAR-10 数据集对 50 个节点进行了模型训练，假设每个节点的数据分布是已知的。为了消除模型迭代次数的影响，我们以同步方式模拟了节点选择过程。在每一轮分组中，除了获得分组所需的 p 个节点外，我们还等待额外 e 个节点接受邀请，然后从接受邀请的节点集中选择节点。在每一轮中，我们都会等待所有节点完成一轮本地训练，然后进行多轮节点选择以完成所有节点的分组。每次我们从剩余的未选择节点中随机选择 p 加 e 个节点来模拟每次领导者收到的追随节点。我们从这组节点中生成所有可能的节点组合，计算每个组合内的数据分布与全局数据分布之间的相似度。与全局数据分布相似度最高的组合被选为此次分组，而其余节点则等待下一次选择。我们使用 Kullback-Leibler (KL) 散度来衡量分组与全局数据分布之间的相似度，KL 散度越小，表示相似度越高。作为对比，我们在相同条件下随机选择分组节点。我们测试它们在相同聚合轮次下的模型准确性。结果表明，在两种情况的 non-IID 数据下，组内数据分布接近全局数据分布的分组聚合后的模型在相同轮数内都能达到更高的精度。




图 2. 在两种 non-IID 数据情况下，考虑数据分布进行分组与不考虑数据分布随机分组的准确性比较。左侧表示在 $c=2$ 的 non-IID 数据下进行训练，右侧表示在 $\alpha=0.1$ 的 Dirichlet 分布采样数据下进行的训练。

在联邦学习中，为了保护客户隐私，节点的数据分布信息通常是不共享的。受 FedGS 的启发，我们根据节点输出层参数的相似性来推断节点数据分布的相似性。具体来说，领导者在接收到的模型中引入一批随机高斯噪声，计算其输出层之间的相似性并构建相似性矩阵。领导者从所有可能的节点组合中选出相似度最低的组合作为当前聚合分组。需要注意的是，由于节点数据分布的复杂性和之前迭代对模型参数的潜在影响，这种推理方法可能无法找到最接近全局数据分布的组合。不过，通过参数的相似性，我们可以尽量避免在聚合分组内引入过多将数据分布相似的节点，有助于保持组内数据的多样性，从而防止聚合模型偏向于特定类型的数据。这种方法构建包含不同数据分布的聚合分组，有利于模型更快地收敛到一致状态。

(2) 历史信息。每次构建分组时，分组邀请信号的到达和接收都是随机的。因此，在训练过程中，每个节点都有机会在通信阈值范围内与其他节点形成分组。整个通信图是连通的，当节点在不同分组之间流动时，模型更新可以在系统中传播。在大多数情况下，这种到达的随机性可

以在几轮内构建一个节点通信的连通图，只有少数特殊情况会形成孤立的子图。孤立子图会影响对数据的充分利用。为了避免出现孤立子图，我们一段聚合轮次后将节点的历史分组信息纳入节点选择中。具体来说，每轮聚合后节点都会记录当前组成员和当前训练轮次。当最近聚合轮次与当前轮次的差小于阈值时，节点被认为与追随者最近有过通信。追随者在发出追随信号的时候将最近通信的节点列表发送给组长。在一定次数聚合后，组长将把历史信息加入构建聚合分组的考虑里。当组长判断当前轮次需要考虑历史分组信息后，组长会在节点选择时同时考虑追随者的历史信息 and 模型相似度。组长首先计算所有可能的节点组合及其相应的相似度得分。组长根据相似度得分对节点集合进行升序排序，并依次计算每个集合的连通性。如果出现孤立子图，则表明该集合中的某些节点对在一定时间内没有直接或间接的通信。组长会选择具有孤立子图中相似度最小的集合作为当前聚合分组。如果不存在孤立子图，则表明用于选择的节点在近期内都有过通信。此时，组长选择相似度最小的节点集作为当前聚合分组。




图 3. 节点选择

3 实验结果

3.1 实验设置

(1) 模型和数据集。我们考虑了卷积神经网络(CNN)在 Fashion-MNIST、CIFAR-10 和 SVHN 数据集上的图像分类任务。CNN 由 3 个卷积层和 2 个全连接层组成。我们采用小批量随机梯度下降算法 (SGD)，批量大小为 32，每次实验的学习率设置为 0.01。

(2) 数据异构。我们考虑了两种 non-IID 数据设置。一种是基于标签数量不平衡的数据异构 ($C=K$)，每个节点都有一个随机分配了 k 类标签的数据子集。另一种是基于分布采样的数据异构 $p_k \sim \text{Dir}(\alpha)$ ，根据 Dirichlet 分布将每个标签一定比例的样本分配给每一个节点。 α 的值越小，表示数据分布越不平衡。

(3) 系统异构性。为模拟确定性异构，我们为每个边缘设备分配了不同数量的 CPU 内核，上下限为 2-6 个 CPU。为了模拟非确定性异构，我们在每一轮训练中为每个节点注入从指数分布中采样的额外延迟，平均延迟为 5 秒。同时，网络拓扑每 200 秒变化一次。

3.2 性能对比

为了更好地说明 AMAS 的性能，我们分别在 IID 和 non-IID 设置下比较了不同方法在没有动态异构和具有动态异构下的性能。如图 4 和表 1 所示，与基线相比，AMAS 在相同的训练时间内获得了更高的训练精度和收敛质量。在没有动态异构的环境下，AMAS 有效地利用了节点的计算资源，实现了模型更新在节点间的快速传播。在具有动态异质性的环境中，由于不依赖于固定结

构，AMAS 受到的影响较小，仍能保持良好的性能。在 non-IID 设置下，与 AD-PSGD 和 Gossip Learning 相比，AMAS 能够一次聚合更多的节点。聚集更多的模型参数可以捕获更多的数据特征，从而减轻模型偏差的影响。




图 4. 确定性异质性或非确定性异质性、IID 数据分布或非 IID 数据分布的收敛速度比较。

			Parameter Server	Gossip Learning	AD-PSGD	KMA_RAF	AMAS
			Accuracy(%)	90.99	90.87	90.22	91.27
IID	deterministic	Speed(s)	1330	620	490	670	420
		Accuracy(%)	87.53	90.11	90.38	88.49	90.93
	non-deterministic	Speed(s)	1470	690	620	1270	540
		Accuracy(%)	83.88	70.26	75.68	85.49	86.05
non-IID	deterministic	Speed(s)	940	1690	1150	530	250
		Accuracy(%)	83.56	69.68	80.86	82.87	84.48
	non-deterministic	Speed(s)	930	1940	640	970	450
		Accuracy(%)	88.61	90.99	90.87	90.22	91.27

表 1. AMAS 的性能。准确度：IID 设置在 1500 秒内达到的最高准确度，non-IID 设置在 2000 秒内达到的最高准确度；速度：达到指定准确度所需的时间（设置分别为 70%、88%、69%、87%）。

为了验证所选节点在不同数据集和数据分布上的有效性，我们在常用数据集 Fashion-MNIST、CIFAR-10 和 SVHN 上进行了训练。数据分布分别设置为 $p_k \sim \text{Dir}(0.1)$ 、 $C=2$ 、 $C=3$ 。在选择节点时，我们根据节点的模型相似性推断数据分布的相似性。为了验证这种方法也能产生数据分布更接近全局分布的分组，我们在训练过程中记录了所有生成的分组。我们使用余弦相似度和 KL 散度来衡量每个组的节点数据分布与全局数据分布之间的相似度。余弦相似度越高，KL 散度越小，说明相似度越高。如表 2 所示，经过选择后，组内的数据分布可以与全局数据分布更加相似。我们比较了选择节点和不选择节点两种方法在 1500 秒的训练时间内所能达到的最高精度，以及收敛到指定精度所需的时间。具体来说，我们计算了 Fashion-MNIST、CIFAR-10 和 SVHN 分别收敛到 50%、80% 和 70% 的准确率所需的时间。如表所示，选择节点有助于模型的收敛。

	Fashion-MNIST		CIFAR-10		SVHN	
	selected	unselected	selected	unselected	selected	unselected
KL divergence	0.4438	0.4676	0.2531	0.3288	0.1998	0.2341
Cosine Similarity	0.7259	0.7167	0.8493	0.8168	0.8533	0.8396
Accuracy(%)	55.73	53.39	88.28	88.36	78.90	76.28
Speed(s)	770	1090	330	380	560	710

表 2. 所选节点的有效性。分组数据分布和全局数据分布(第 2-3 行)之间的相似性的平均值以及所选节点的性能(第 4-5 行)。精度:1500s 达到最高精度;速度:达到指定精度所需的时间(根据不同的设置, 分别为 50%、80%、70%)。

4 总结

4.1 已完成工作

①探讨了现实环境中现有聚合结构方法存在的问题。现有的聚合方法无法适用大规模动态的边缘环境。

②提出启发式的解决方案。通过协议让节点自主构建聚合结构, 在聚合时考虑真实运用场景会遇到的动态异构、non-IID 问题。

4.2 未来工作

① 使用强化学习等更智能的方式优化模型聚合结构。强化学习可以优化聚合分组的大小、等待时间以及节点选择。

② 考虑更为实际和具体的应用场景, 我们期望获得更全面和更适应真实世界的解决方案。

与课题相关的学术成果情况:

暂无

二、中期考核作者承诺及导师意见

我保证上述填报内容的真实性, 并将在导师指导下, 严格遵守学校的有关规定, 按计划认真开展学位(毕业)论文研究工作。

研究生(签名):

年 月 日

我已审阅过中期考核的全部内容, 同意研究生参加中期考核。

指导教师(签名):

年 月 日

三、中期考核审核意见

中期考核小组成员名单			
组成人员	姓 名	职 称	工作单位
组长			
成员			
成员			
成员			
成员			
成员			
成员			
成员			

审 核 意 见	具体意见：
	审核结果： ☐ 通过 ☐ 暂缓通过
	组长签名：
	成员签名：
	年 月 日
院 (系) 意 见	主管领导签名： 院（系）公章 年 月 日