

林肯达中期答辩逐页讲稿

面向大模型的数据与参数联合高效微调算法研究

本讲稿对应优化后的 27 页 PPT，其中 25 页用于主讲，2 页供问答使用。主线是介绍 PCU Select 当前进展，再说明多配置实验管理系统的两项工程机制和后续工作安排。每页提供口语讲稿、转场句与讲述提示。

使用与时间安排

正文计划用时 15 分 0 秒，按约 15 分钟准备。首次排练请计时，章节页简短过渡，算法流程与系统复用规则可以放慢。问答时按需要跳转第 26 或 27 页。

第 01 至 05 页 课题进展概览，约 1 分 51 秒。

第 06 至 12 页 PCU Select 方法与当前进展，约 5 分 1 秒。

第 13 至 20 页 系统方案与工程机制，约 5 分 59 秒。

第 21 至 25 页 后续计划与总结，约 2 分 9 秒。

汇报前需要核实的内容

PPT 沿用原开题总题目和汇报人信息。后续安排为建议的相对 8 周计划，应按学院截止日期和实际实验资源调整。系统部分是拟开展工作，不能讲成已经完成。

实验数据已更新为真实运行结果。

逐页讲稿 01 至 04

第 01 页 面向大模型的数据与参数联合高效微调算法研究

时间 建议 20 秒

各位老师好，我是林肯达。今天汇报的课题是《面向大模型的数据与参数联合高效微调算法研究》。本次是中期答辩，我会重点说明已经开展的 PCU-Select 算法工作，以及接下来计划完成的实验管理系统。

转场 下面按四个部分汇报。

提示 完整读出总题目，明确“中期”定位。

第 02 页 目录

时间 建议 12 秒

首先交代开题目标与当前进展；接着介绍工作一的方法和验证边界；然后说明工作二的系统方案；最后汇报后续八周的建议计划与交付标准。

转场 先看课题目前推进到了哪里。

提示 快速指过四项，不展开技术细节。

第 03 页 01 课题进展

时间 建议 6 秒

第一部分是课题进展，重点说明研究目标怎样落实为两项可以完成和验证的工作。

转场 先对齐开题目标和中期聚焦。

提示 章节页短暂停顿后翻页。

第 04 页 开题目标与中期聚焦

时间 建议 38 秒

开题时，我希望同时考虑训练数据和可训练参数，降低大模型适配任务的成本。中期阶段，这个目标进一步聚焦为两项工作。第一项是 PCU-Select：给定任务和微调配置，选择更适合的数据。第二项是实验管理系统：当任务、配置和预算反复组合时，管理可复用计算与实验产物。开题中的动态路由方向暂时收敛为后续展望，当前优先把这两项工作的实现和验证做完整。

转场 两项工作处于不同阶段，下面分别说明。

提示 强调总目标延续，研究内容有所聚焦；不要把动态路由说成已完成。

逐页讲稿 05 至 07

第 05 页 当前进展与待完成工作

时间 建议 35 秒

目前已经形成论文稿件和算法实现，包括特征缓存、任务表示、PEFT 编码、条件评分、聚类配额，以及训练评测脚本。这里的“已有”主要指方法和代码资产。实验数据已更新为真实运行结果。第二项工作目前处于方案阶段，分层依赖缓存、公共节点去重和恢复机制将作为后续新增内容。

转场 接下来先介绍已经形成的方法。

提示 区分已有研究进展与计划新增的系统工作。

第 06 页 02 工作一 PCU Select

时间 建议 6 秒

第二部分介绍工作一，核心是让数据选择感知具体的微调配置，同时复用前期计算。

转场 先说明为什么选数要同时考虑配置和任务。

提示 PCU-Select 读作字母加 Select 即可。

第 07 页 数据价值由样本、配置和任务共同决定

时间 建议 46 秒

PEFT 是参数高效微调，也就是只更新模型中的一小部分参数。不同配置会改变能更新的位置和容量。因此，同一道练习题对不同学习方式的帮助可能不同，数据价值也不能只看样本本身。我用 $u(x,p,t)$ 表示这种条件效用： x 是样本， p 是微调配置， t 是目标任务。目标是在有限预算内选出有帮助的子集。逐一训练所有候选子集代价太高，所以需要学习一个评分器，近似判断每条样本对当前配置和任务的作用。

转场 为了让同一个评分器处理不同配置，需要先把三类信息表达清楚。

提示 解释一次练习题类比，再回到 x 、 p 、 t ；强调这是要验证的建模假设。

逐页讲稿 08 至 10

第 08 页 样本、PEFT 与任务 在共享位点上表达

时间 建议 50 秒

评分器读取三类表示。样本表示包括语义、难度和激活特征；任务表示由少量任务样本的表示平均得到；PEFT 编码记录作用位置、更新类型、容量和训练配方。不同微调方法的参数形状不同，不能直接共用原始参数梯度。因此，方法在模型内部固定观察位置：八个层，每层三个模块输出，共二十四个位点。可以把它看成固定的测量坐标。不同配置保留自己的作用方式，同时共用这些坐标下的样本信号。位点梯度主要服务于离线标签构造，不直接等同于全部参数梯度。

转场 表示解决了如何输入，接下来需要说明评分器从什么信号学习。

提示 先讲三种表示分别回答什么，再解释 8×3 ；不要朗读所有维度。

第 09 页 多保真监督与聚类配额

时间 建议 55 秒

多保真指两种成本和直接程度不同的监督信号。低保真比较样本与任务在共享位点上的梯度方向，便宜，适合覆盖大量数据。高保真则做少量真实更新，观察任务样本集的损失是否下降，更直接，但仍然只是小批次短期作用，不能当成长程训练的真实贡献。评分器学习这些信号后，输出效用和不确定性，再对不确定性作惩罚。最后不直接全局取最高分，而是先按语义分簇，根据每个簇的价值和规模分配预算，再在簇内取高分样本，从而兼顾效用与覆盖。

转场 把这些模块连起来，就是方法的完整流程。

提示 按“标签从哪来→如何评分→怎样选集”顺序，配额公式只讲价值和规模。

第 10 页 PCU Select 完整流程

时间 建议 48 秒

整体分成离线和在线两部分。离线阶段提取并保存样本特征、任务表示和位点信号，构造两类监督标签，训练条件评分器。这部分构成前期投入。在线阶段输入目标 PEFT 和任务，读取缓存，计算条件分数，再通过聚类和配额生成预算内子集，最后进入下游训练评测。这里复用的是特征和评分器，每个目标仍然使用自己的子集。对于超出训练支持范围的配置，需要按验证情况选择校准或其他选数方案，不能默认所有新配置都能直接使用。

转场 评价时，我分别考察最终质量和选择侧成本。

提示 沿流程箭头讲，突出“复用公共资源 + 保留目标条件”。

逐页讲稿 11 至 13

第 11 页 稿件中的质量与成本分析口径

时间 建议 58 秒

这一页保留实验中的三个比较口径。质量方面，PCU-Select 的任务原生指标宏平均是三十五点一八，LESS 是三十五点一四，只能说稿件均值接近，不能据此宣称显著领先。选择成本方面，五套配置的合计分别是一百五十一.六和三百一十六个 GPU 小时；新增一套四任务配置的边际成本分别是一点五一和六十三点二。总成本包含前期摊销，边际成本描述新增目标，两者都排除下游训练。

转场 所以，中期阶段需要把方法进展和实验结论的成熟度分开说明。

提示 每组数字先报口径再比较；说明质量与成本的比较范围。

第 12 页 工作一小结与验证边界

时间 建议 38 秒

工作一已经形成共享位点、条件评分和聚类配额的整体方法，也有对应代码与实验入口。实验记录需关联数据版本、训练种子、配置与表格结果。方法本身也有边界：短更新只近似长期收益，共享位点是结构近似，现有范围不能直接推出跨模型家族的普遍结论。

转场 当这些算法资产被反复用于实验时，就引出了第二项工作。

提示 小结先讲已有成果，再说明实验范围。

第 13 页 03 工作二 实验管理系统

时间 建议 6 秒

第三部分是计划开展的工作二，将工作一的算法资产组织成可重复执行、可追溯的系统。

转场 先说明系统要解决的具体问题。

提示 明确本部分属于拟开展工作。

逐页讲稿 14 至 16

第 14 页 系统目标与已有基础

时间 建议 44 秒

重复做多任务、多配置实验时，会不断遇到三个问题：哪些旧结果还能用，相同计算是否重复执行，以及失败后从哪里继续。第一工作已经提供了特征缓存、任务表示、条件评分、聚类配额、PEFT 注册和实验脚本。第二工作将补上依赖清单、版本判定、公共节点执行以及请求独立目录。现有脚本已经能循环运行实验矩阵，所以新增内容重点是让复用规则可检查，让执行状态和产物对应清楚，而不是重新设计一套评分算法。

转场 第一项工程机制先回答：一个产物什么时候还能复用？

提示 对照“已有资产→新增能力”，不要说系统已上线。

第 15 页 机制一 分层缓存与依赖清单

时间 建议 50 秒

分层缓存可以理解成给每份中间结果附上来源清单。样本特征依赖样本内容、模型和预处理；任务表示依赖任务样本与表示方式；评分再依赖目标 PEFT、任务表示和评分器版本；聚类依赖完整候选池的语义特征；子集依赖评分、聚类和预算。系统计划记录内容摘要、配置、随机种子及产物校验值。这样即使样本名字没变，只要内容变了，也能识别旧结果已经不适用。变化发生后，只沿受影响的依赖向下重算。

转场 这些依赖关系对应几条明确的复用规则。

提示 用“来源清单”解释依赖；指一条完整的样本到子集路径。

第 16 页 输入变化后 复用什么 重算什么

时间 建议 60 秒

第一种情况，只改选数预算。评分和聚类不变，重新分配配额并生成子集即可。第二种情况，选择条件和选择种子都不变，只改下游训练随机种子，那么直接复用子集，重新训练和评测。第三种情况，候选池新增样本，而且评分条件不变，可以保留旧样本兼容的特征和逐样本分数，只补算新增样本。但整个数据池变了，完整池的聚类、配额和子集仍要重算。候选顺序也要进入依赖。另外，学习率等训练配方进入了 PEFT 编码，不能把它们的变化误当成仅改变训练种子。

转场 有了正确的复用判定，还需要保证一批请求能够可靠执行。

提示 逐行讲三个变化案例；最后专门区分训练种子与训练配方。

逐页讲稿 17 至 19

第 17 页 机制二 公共计算去重与阶段恢复

时间 建议 54 秒

第二项机制把请求拆成特征、任务表示、评分、聚类、选数、训练和评测等阶段。两个请求如果某个阶段的输入依赖完全相同，就指向同一个计算节点，计划只执行一次。写结果时，先写临时文件，检查完整性后再原子发布，并记录完成标记；各请求则使用自己的目录和记录，避免互相覆盖。中断后，已经完成且校验通过的产物继续复用，只重跑失败或尚未完成的阶段。这里的恢复以阶段为单位，首版不承诺训练内部每一步的断点续训。

转场 下面用一个小矩阵说明哪些计算能共享。

提示 解释“原子发布”为写完整后一次性变成可用；恢复边界要讲清。

第 18 页 24 次训练实验的共享计划示例

时间 建议 52 秒

以同一候选池为例，两种 PEFT、两个任务、三个预算和两个训练种子，共有二十四次训练。固定特征、评分器、聚类配置和选择种子后，PEFT 与任务形成四种目标条件，因此需要四份评分。聚类只依赖这一份完整池的语义特征，所以可共享一份。四种条件各做三个预算，得到十二份子集，每份子集再使用两个训练种子，完成二十四次训练。各任务和配置仍保留自己的子集。这是计划中的节点数量示例，既不是现有系统的实测结果，也不等于端到端加速倍数。

转场 围绕这一类实验矩阵，首版系统保持明确的实现范围。

提示 依次指 4→1→12→24；提醒计数未包含全部离线工作与 I/O。

第 19 页 首版系统范围与操作流程

时间 建议 38 秒

首版采用单工作节点，不把分布式调度作为当前目标。系统包括任务队列、元数据索引和本地产物库，并提供简洁控制台。用户先登记数据与任务，再提交实验矩阵，查看预计复用和重算哪些阶段，然后执行选数，按需要接入训练评测，最后导出报告。支持范围继续沿用第一工作已经核验的骨干与 PEFT；尚未完成真实验证的配置只保留为待验证项。

转场 系统做出来后，需要用对照实验验证两项机制的价值。

提示 沿操作流程从左到右；不要把控制台设计图称为实际运行截图。

逐页讲稿 20 至 22

第 20 页 两项工程机制的定量验证计划

时间 建议 55 秒

验证计划分三组：已有脚本流程、加入依赖缓存、完整系统。已有脚本本来就缓存部分特征，因此比较时保留这项基础。机制一测试改预算、改种子、增加样本和同名样本改内容，记录各层重算数量、时间与存储，并检查结果是否与完整重算一致。机制二运行同一批实验矩阵，记录实际执行次数，再注入中断，测恢复时间、重复工作和结果隔离。选择阶段与端到端耗时分开报告。缓存和节点去重的收益可能重叠，不能把两项节省比例相加，提升幅度以最终测量为准。

转场 最后说明如何在中期之后完成实现和验证。

提示 先说三组对照，再对应两项机制的场景与指标；不预填提升比例。

第 21 页 04 后续计划

时间 建议 6 秒

第四部分是后续计划。我以中期答辩后八周为建议周期，将实现和实验核验并行推进。

转场 每两周设置一个可检查的里程碑。

提示 明确八周为相对建议计划，不是已确认的校历安排。

第 22 页 建议 中期答辩后八周里程碑

时间 建议 50 秒

第一到第二周，固定系统范围和评分器版本，整理依赖清单、请求规范，并拆开评分、聚类 and 配额接口。第三到第四周，完成内容摘要、版本判定和局部重算，覆盖预算、种子与样本变化场景。第五到第六周，接入队列、公共节点、阶段恢复、结果隔离和控制台，跑通矩阵示例。第七到第八周，完成机制对照与故障实验，整理报告和论文。同时整理第一工作的实验记录和论文结果。

转场 完成与否，将用具体交付和验收标准判断。

提示 每阶段只讲任务和一个交付；强调双线并行及相对建议性质。

逐页讲稿 23 至 25

第 23 页 预期交付与验收标准

时间 建议 38 秒

预期交付包括四项：第一，可运行的单节点系统，能够完成从矩阵提交到报告导出的流程；第二，带版本和依赖记录的实验产物；第三，两项工程机制的对照评价报告；第四，由实验结果支撑的论文。验收时重点检查：复用结果与参考重算是否一致，过期或损坏产物是否能识别，不同请求是否互不覆盖，中断后是否只重复必要阶段。效率提升不预设结论，由实际测量给出。

转场 两项工作共同服务于课题最初的高效微调目标。

提示 将“验收目标”和“已经达到”明确区分。

第 24 页 两项工作总结

时间 建议 25 秒

总结来说，工作一研究在不同任务和微调配置下如何选择数据，已经形成方法与代码基础；工作二计划把这些资产组织成可复用、可恢复、可追溯的实验系统。后续重点是完成两项工程机制的实现和定量验证。

转场 以上是我的中期汇报。

提示 用一句话对应每项工作，收束到剩余任务。

第 25 页 谢谢各位老师 敬请批评指正

时间 建议 10 秒

我的汇报到此结束。感谢各位老师的时间，恳请老师们对研究边界、验证方案和后续工作安排提出意见。

转场 根据老师提问展开回答。

提示 停留本页，准备根据问题调用两页备用内容。

备用页讲述

第 26 页 备用 缓存键与恢复边界

缓存键不能只使用样本名或文件路径。特征要记录样本内容摘要、模型权重与预处理版本；任务表示要记录任务样本和编码配置；评分还要加入 PEFT 编码、评分器及必要校准版本；聚类要加入完整池顺序、语义特征、聚类参数和种子；子集要加入预算、配额参数和确定性的排序规则。训练另有随机种子和运行配置。恢复时，完成标记和校验必须同时通过；只有文件存在还不够。若训练阶段失败，首版从该训练阶段重新执行，不承诺模型训练内部 step 的断点恢复。

转场 这样可以将复用判定与产物完整性分开检查。

提示 只回答被问到的层级，不必全文朗读。

第 27 页 备用 数据核验与支持范围

目前主表按任务、配置和训练种子组织实验结果；计时也需要关联硬件、配置和原始阶段日志。复现实验时，应为每个实验记录数据版本、模型、PEFT、选择与训练种子、指标和产物路径，再由日志重建表格。系统首版以已经真实核验的骨干与 PEFT 为支持范围；仅在注册表或代码中出现，不代表完成了相同程度的实验验证。新增家族和跨骨干扩展列为后续验证事项。

转场 各项结论对应具体实验配置与计时口径。

提示 说明实验配置、统计口径与后续研究范围。

常见追问 01 至 04

01 两项工作之间是什么关系 为什么第二项不只是给算法做界面

第一项提供条件评分器、特征缓存、PEFT 编码与选数算法。第二项围绕这些产物建立内容和版本依赖、增量失效、公共节点执行以及故障恢复规则。界面只是操作入口，拟验证的贡献是错误复用能否避免、重复计算能否减少、恢复代价能否降低。它的定位是系统与工程机制，不额外宣称新的评分算法。

对应 PPT 14–20

02 开题里的动态路由为什么不作为当前主线

中期将数据与参数协同这一总目标聚焦到可完成、可验证的两项工作。后续基于条件选数方法完成多配置实验系统。动态路由保留为后续展望，不把未完成的方向算作已有成果。

对应 PPT 4、22

03 35.18 比 35.14 高 能说明方法显著优于 LESS 吗

不能。这是稿件任务原生指标的宏平均，不是一个统一准确率；数值非常接近。质量结论需结合逐任务结果与不确定性分析，不宣称显著领先。

对应 PPT 11–12、27

04 总成本与边际成本为什么不同 是否包括训练

总成本比较多配置选择工作时计入前期共享投入；边际成本描述已有共享资产后，再增加一套四任务 PEFT 配置的选择工作。实验结果为五配置 151.6 对 316 GPU 小时，边际 1.51 对 63.2 GPU 小时。两者都排除下游训练

对应 PPT 11

常见追问 05 至 08

05 新增数据后为什么能复用旧分数 却不能直接复用聚类

在特征、任务、PEFT 和评分器等条件不变时，旧样本的评分是逐样本计算，其兼容结果可以保留。聚类使用完整候选池，新增样本可能改变中心、分组和簇大小，所以首版重新计算完整池聚类、配额及子集。候选顺序也进入池级依赖。

对应 PPT 15–16、26

06 是否只要训练参数改变 就能继续用原来的子集

不是。当前复用规则只针对选择条件和选择种子不变、仅下游训练随机种子改变。学习率、batch size、dropout、max_steps、scheduler 等配方会进入 PEFT 编码，它们改变时需要更新条件评分及相关下游。

对应 PPT 16、26

07 24 次实验怎么变成 4 份评分和 1 份聚类 是不是有 24 倍加速

两个 PEFT 与两个任务形成四种评分条件；相同完整池及顺序、语义特征、聚类参数和种子允许共享一份聚类。四条件乘三个预算生成十二份子集，每份两个训练种子仍需二十四次训练。这里只是计划的节点数量，没有计入所有离线工作、训练和 I/O，也不是实测，更不代表端到端加速倍数。

对应 PPT 18

08 分层缓存和公共计算去重会不会重复计算同一项收益

会有重叠，所以计划用已有脚本、加入依赖缓存、完整系统三组对照，并分别测试顺序输入变化、冷缓存批量请求和故障恢复。不把两个机制的节省比例相加。单工作节点下某些场景可能有相同执行次数，届时如实报告，并进一步比较恢复代价、复用计划和产物隔离。

对应 PPT 20

常见追问 09 至 10

09 中断恢复是从训练的某一步继续吗 如何防止读到半个文件

首版以阶段为恢复单位。已完成且校验通过的上游产物可继续用；训练阶段失败时重新执行该阶段，不承诺训练内部 step 续训。产物先写临时文件，完成校验后原子发布，再登记完成状态。文件存在但没有有效完成记录，或者校验不通过，都不能直接复用。

对应 PPT 17、26

10 后续计划怎样证明已经完成 而不是只做出一个演示界面

验收包含完整矩阵流程、版本依赖和可追溯产物；预设变更场景与参考重算一致；过期或损坏产物能被识别；不同请求结果隔离；故障恢复只重复必要阶段；并提供真实的时间、执行次数和存储对照报告。几周是中期后的建议相对安排。

对应 PPT 22–23、27