

学位论文进展情况及下一阶段工作重点

2026 年 9 月 7 日

本学位论文围绕大语言模型参数高效微调中的数据选择问题展开。目前已完成第一份工作 PCU-Select 的论文撰写，下一阶段拟以已有算法和代码为基础，开展多配置数据选择与微调实验管理系统的设计、实现和验证，形成算法研究与工程应用相衔接的两个工作点。

一 当前学位论文进展情况

研究问题与方法。第一份工作针对不同参数高效微调 (PEFT) 配置下样本价值不同、逐配置重建梯度数据存储开销较高的问题，提出 PEFT 条件效用建模方法。通过 24 个共享干预站点、样本与任务表征以及结构化配置编码，复用离线计算，为不同任务和配置生成各自的数据子集。

实现与实验基础。已形成特征缓存、多保真标签构造、条件评分、聚类配额选择及配置迁移校准的实现框架。论文稿已呈现 Llama-2-7B 上 GSM8K、HumanEval、MMLU 和 TyDiQA 四项任务、五种已见 PEFT 配置的主要比较，并包含动机实验、消融、迁移和成本分析。

阶段性结果。论文当前报告的四任务指标宏平均为 35.18，逐配置 LESS 为 35.14，支持平均效果接近的结论。在一次性离线投入 144.0 GPU 小时后，支持范围内新增一个四任务 PEFT 配置的边际选数成本由 63.2 降至 1.51 GPU 小时，约降至原来的 1/42；该比较不包含下游微调成本，也不表示训练全过程加速 42 倍。

当前阶段与待完善内容。现有实现主要通过脚本组织实验，已有离线缓存与配置注册基础，但尚需完善产物版本依赖、批量请求复用、结果隔离和失败恢复。后续将核对原始日志与图表口径，把第一份工作整理为算法章节，并将上述工程问题作为第二项工作的切入点。

二 下一阶段工作重点

下一阶段以 PCU-Select 的工程化落地为重点，将已有特征提取、评分、聚类选数及训练评测模块封装为统一流程。系统支持登记数据池和任务、批量提交 PEFT 配置与选数预算、查看执行状态，以及导出所选数据、指标和成本报告。

核心工作是实现依赖感知的分层缓存、增量复用和公共计算去重。通过重复请求、数据追加和任务中断实验，验证结果一致性、执行效率与恢复能力，完成系统原型、实验分析及学位论文撰写。

三 第二个工作点简要方案

建议题目 基于 PCU-Select 的多配置数据选择与微调实验管理系统

第二项工作直接使用第一项工作的评分器、特征缓存、PEFT 编码和聚类配额算法，解决重复开展多任务、多配置实验时的产物管理与执行效率问题。预期成果是一套可运行系统，以及两项能够定量验证的工程机制。

已有基础	第二项工作增加的内容
样本特征和任务表征缓存	记录内容及版本依赖，识别可复用产物并局部重算
条件评分与聚类配额选数	复用公共评分和聚类，为各预算独立生成子集
PEFT 注册及训练评测脚本	统一批量执行、阶段恢复、结果隔离与报告导出

工程机制一 分层缓存与增量复用。为样本特征、任务表示、评分、聚类和选择结果建立依赖清单，记录样本内容摘要、模型与评分器版本、预处理配置、随机种子及产物校验值。输入变化后，沿依赖关系仅重算受影响的节点，避免同名样本或不同预算错误命中旧结果。

复用规则。仅改变选数预算时，复用评分和聚类，重算配额与子集；选择种子不变、仅改变下游训练种子时，复用选择结果。增加候选样本且评分条件不变时，复用旧样本的兼容特征与逐样本评分，只补算新增样本；完整池的聚类与配额仍需重算。候选顺序纳入依赖，首版固定评分器版本。

工程机制二 公共计算去重与阶段恢复。把实验请求拆分为特征、任务表示、评分、聚类、选数、训练和评测节点；输入依赖相同的节点只执行一次。通过原子写入、完成标记和请求独立目录，避免结果覆盖；中断后复用已完成产物，仅重跑失败阶段。

具体示例。同一数据池上的 2 种 PEFT、2 个任务、3 个预算和 2 个训练种子，对应 24 次训练实验。固定特征与评分器版本、聚类配置及选择种子后，可共享 4 份目标评分和 1 份聚类，生成 12 份子集，再完成 24 次训练。各任务与配置仍使用各自子集；上述次数不等于端到端加速倍数。

系统范围。首版采用单工作节点、任务队列、元数据索引和本地产物库，提供简洁控制台。操作流程为登记数据与任务、提交实验矩阵、查看复用计划、执行选数、按需训练评测、导出报告。继续沿用第一项工作已验证的骨干与 PEFT 支持范围。

四 实验验证与推进安排

结果正确性。沿用第一项工作的小规模任务与配置，固定算法、硬件、精度和随机种子，对照优化前后的评分数值、所选样本及顺序。覆盖文本变更但样本 ID 不变、预算变化、评分器版本变化等情况，验证缓存正确失效；代表性训练评测用于确认系统优化未改变原算法效果。

复用与增量效率。按 1、3、5 种受支持配置组织多任务、多预算请求，分别比较顺序执行、分层缓存、缓存加公共节点去重。候选池追加 1%、5%、10% 样本，对照全量重算与增量执行，记录重算样本数、重复节点数、完成时间、缓存命中率和存储开销。

恢复与对照口径。在产物写入和阶段切换处模拟中断，检查半成品不会被复用，以及恢复后的结果一致性。对照组保留已有特征缓存与模型复用，并消除同一请求内明显的重复评分。冷启动、热缓存和追加场景分别报告，CPU 耗时与实际 GPU 占用分开统计，共享节点仅计费一次。

首版与系统验证建议按 6 至 8 周推进，优先完成核心执行流程，再补齐展示界面。

阶段	工作重点	阶段产出
第 1 周	梳理已有模块，定义产物依赖、缓存边界与基准请求	系统设计及验证方案
第 2 至 3 周	实现版本缓存、增量特征与评分、公共节点去重	可运行的核心流程
第 4 至 5 周	接入训练评测，完成阶段恢复、控制台和报告导出	可演示的系统原型
第 6 至 8 周	完成正确性、性能及恢复实验，整理学位论文章节	系统实验结果与论文稿

论文贡献组织。第一项工作论证条件效用建模和跨配置选择质量；第二项工作论证面向该算法的复用边界、增量执行与系统可靠性。通用缓存和实验追踪已有工具支持[1–2]，本工作的工程贡献应由 PCU-Select 专用依赖设计及系统对照实验支撑，主要评价目标是质量保持、效率改善和结果可追溯。

实现参考

[1] DVC 官方文档 [Running Pipelines](#) 依赖检查与运行缓存机制

[2] MLflow 官方文档 [ML Experiment Tracking](#) 实验参数 指标与产物记录